

Projet – Big Data

Analyse de Données de Vente

Contexte

Une entreprise de commerce en ligne souhaite exploiter l'historique de ses ventes afin de mieux comprendre son activité, analyser le comportement de ses clients et identifier des opportunités d'amélioration de ses performances commerciales.

Dans ce contexte, l'entreprise met à disposition un ensemble de données contenant plusieurs centaines de milliers de transactions réalisées sur sa plateforme. L'objectif est de développer **une solution d'analyse de données utilisant Apache Spark** afin de traiter efficacement ces données et d'en extraire des informations pertinentes.

Dataset: Le projet s'appuiera sur le dataset **Online Retail Dataset**. Disponible ici: <https://archive.ics.uci.edu/dataset/352/online+retail> ¹

Ce dataset contient environ 540 000 transactions réalisées par un site de vente en ligne.

Extrait du fichier :

InvoiceNo,StockCode,Description,Quantity,InvoiceDate,UnitPrice,CustomerID,Country 536365,85123A,WHITE HANGING HEART T-LIGHT HOLDER,6,2010-12-01 08:26,2.55,17850,United Kingdom 536365,71053,WHITE METAL LANTERN,6,2010-12-01 08:26,3.39,17850,United Kingdom

Vous êtes libre d'enrichir le dataset, ou de diminuer le nombre de lignes si besoin. L'application devra assurer un minimum de fonctionnalités décrites ci-dessous. Vous êtes encouragés à proposer des améliorations.

Minimum demandé:

Partie 1: Spark

Développez une application d'analyse de données utilisant Apache Spark installé sur votre machine sous docker. Utilisez PySpark. L'application permettra :

- de charger les données ;

¹ Chen, D. (2015). Online Retail [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5BW33>.

- de nettoyer et transformer les données lorsque cela est nécessaire ;
- de réaliser plusieurs analyses pertinentes sur les ventes et les produits et les afficher à l'utilisateur.
- de calculer quelques indicateurs pertinents.

Partie 2: HDFS

On vous demande de stocker le fichier du dataset sur un cluster Hadoop HDFS.

Extension possible: Vous pouvez proposer une application permettant le traitement des données en temps réel.

Présentation finale:

- Lors de la dernière séance, chaque groupe devra présenter son travail (avec démonstration, Durée maximale : 10 minutes). La présentation sera suivie de questions sur le contenu du module.
- Un rapport en PDF représentant votre travail est à déposer sur la plateforme.